





Instalasi Spark+Jupyter di EC2







Instalasi Spark (Minimum)

- Download dari https://spark.apache.org/downloads.html:
 - Contoh:
 - wget https://www-eu.apache.org/dist/spark/spark-2.4.4/spark-2.4.4-bin-hadoop2.7.tgz
- Extract:
 - tar -xvf spark-2.4.4-bin-hadoop2.7.tgz
- Ubah .bashrc:
 - nano ~/.bashrc
- Tambahkan baris:
 - export SPARK HOME=/home/ubuntu/spark-2.4.4-bin-hadoop2.7
 - PATH=\$PATH:\$SPARK HOME:\$SPARK HOME/bin
- Reload .bashrc:
 - source ~/.bashrc
- Test Spark shell atau pyspark:
 - spark-shell
- atau
 - pyspark









PySpark Shell

- Contoh PySpark
 shell →
- Untuk membuat RDD salah satunya bisa menggunakan fungsisc
- parallelize() dariSparkContext

```
ov ubuntu@ip-172-31-46-241: ~
se setLogLevel(newLevel).
Welcome to
Using Python version 3.7.3 (default, Mar 27 2019 22:11:17)
SparkSession available as 'spark'.
>>> x = [1,2,3]
>>> rdd = sc.parallelize(x)
>>> rdd.collect()
[1, 2, 3]
>>> rdd.count()
>>> rdd2 = rdd.map(lambda x: 2*x)
>>> rdd3 = rdd2.reduce(lambda x,y: x+y)
>>> rdd3
12
```



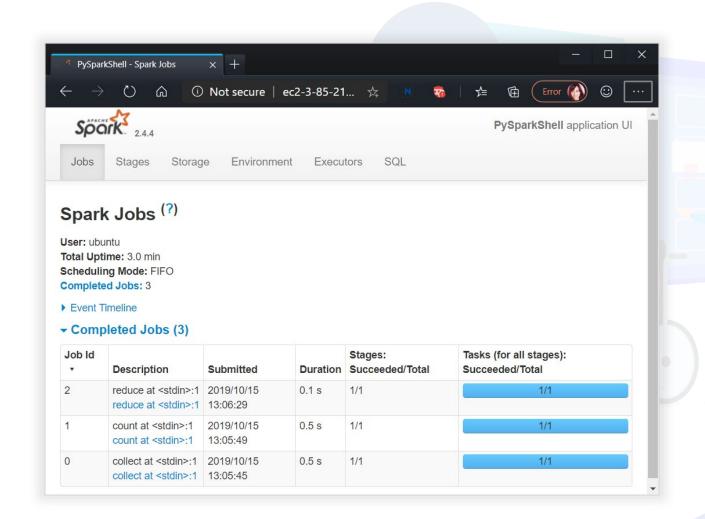
Spark Web UI

- Apabila Spark Shell atau PySpark berhasil dijalankan,
 Spark web UI dapat diakses melalui:
 - http://hostname-ec2:4040
 - Misalnya
 - http://ec2-3-85-216-134.compute-1.amazonaws.com:4040
- Catatan:
 - Port 4040 adalah default
 - Port 4040 di EC2 (inbound) harus dibuka supaya bisa diakses dari luar











Jupyter+PySpark di AWS EC2

- Kebutuhan:
 - Anaconda (dengan Jupyter)
 - Spark
 - Instalasi module findspark
 - pip install findpark

TERBUKA UNTUK DISABILITAS



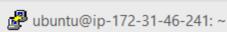
SSH Tunneling di Putty ke EC2

- SSH Tunneling atau SSH Port Forwarding digunakan untuk mem-forward port dari remote server ke local computer melalui koneksi SSH atau sebaliknya
- Dalam kasus ini port Jupyter yang digunakan di EC2 akan di-forward melalui port di komputer lokal
- Untuk mengetahui port mana yang akan digunakan Jupyter, jalankan sekali lalu cek URL dari Jupyter http://localhost:8888/?token=xxx









```
nda3/lib/python3.7/site-packages/jupyterlab
[I 13:26:42.950 NotebookApp] JupyterLab application directory is /home/ubuntu/an
aconda3/share/jupyter/lab
[I 13:26:42.952 NotebookApp] Serving notebooks from local directory: /home/ubunt
[I 13:26:42.953 NotebookApp] The Jupyter Notebook is running at:
[I 13:26:42.953 NotebookApp] http://localhost:8888/?token=3bb28cbbd336c50306b9d8
9f081ad3339d6e6e1311b47794
[I 13:26:42.953 NotebookApp] or http://127.0.0.1:8888/?token=3bb28cbbd336c50306
b9d89f081ad3339d6e6e1311b47794
[I 13:26:42.953 NotebookApp] Use Control-C to stop this server and shut down all
kernels (twice to skip confirmation).
[W 13:26:42.957 NotebookApp] No web browser found: could not locate runnable bro
wser.
[C 13:26:42.957 NotebookApp]
    To access the notebook, open this file in a browser:
        file:///home/ubuntu/.local/share/jupyter/runtime/nbserver-4483-open.html
    Or copy and paste one of these URLs.
       http://localhost:8888/?token=3bb28cbbd336c50306b9d89f081ad3339d6e6e1311b
47794
     or http://127.0.0.1:8888/?token=3bb28cbbd336c50306b9d89f081ad3339d6e6e1311b
47794
```

Misalnya dalam contoh ini yang digunakan adalah port 8888

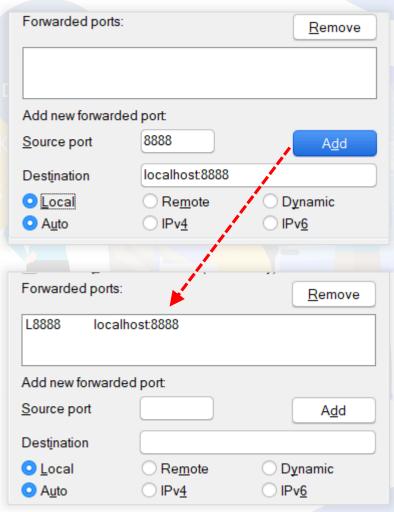






SSH Tunneling di Putty ke EC2

- **Jalankan Putty**
- Isikan di:
- Session
 - Host Name: ec2.... < nama hostname ec2....>
 - Port: 22
- Connection
 - Auth
 - Gunakan fail .pem hasil unduh untuk EC2 ybs.
 - Tunnels
 - Source: 8888 (port di komputer local, usahakan sama dengan destination)
 - Destination: localhost:8888 (Jupyter di EC2)
 - klik tombol Add
- Login dengan user: ubuntu
- Jalankan:
 - jupyter notebook
- atau
 - jupyter lab

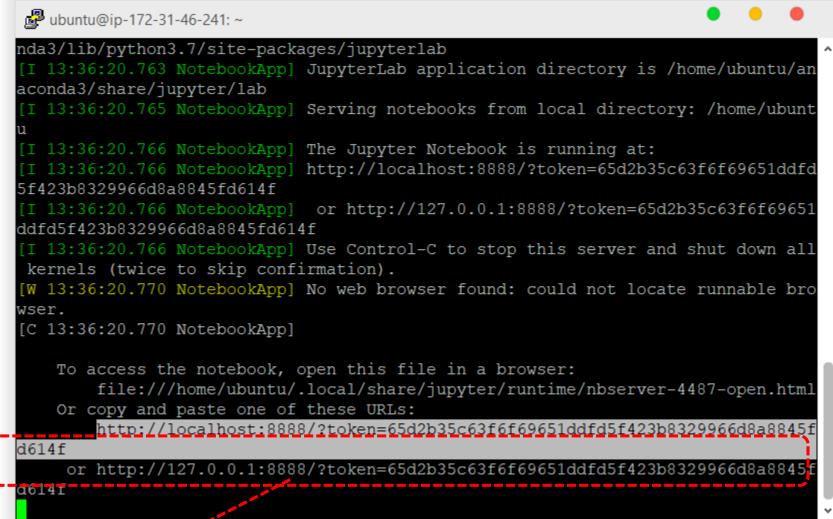












Blok baris ini dengan klik kiri *mouse* (dan otomatis ter-*copy*) JANGAN dengan CTRL+C karena akan menghentikan jupyter server



Akses Jupyter

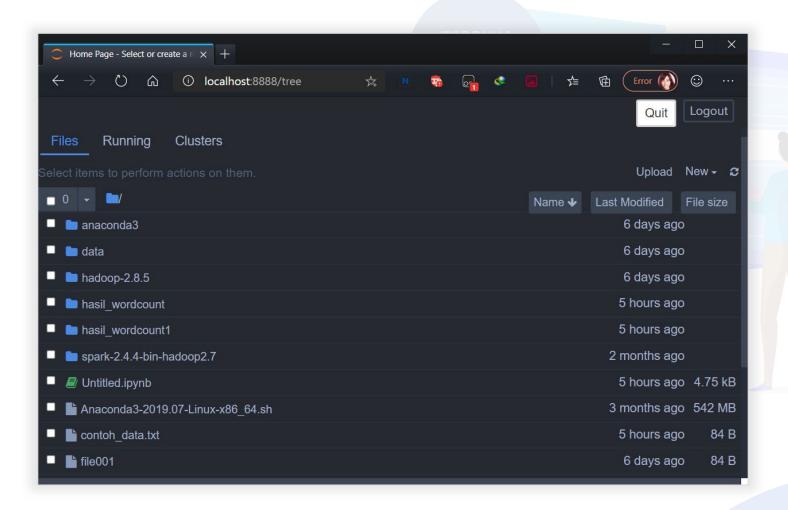
- Untuk mengakses Jupyter yang ada EC2 di peramban komputer kita, maka cukup menggunakan URL yang kita copy sebelumnya.
- Atau ketikkan localhost: port (sesuai port local yang di SSH tunnelling)
 - Untuk yang ini kita perlu token dari URL yang diberikan oleh Jupyter untuk bisa login







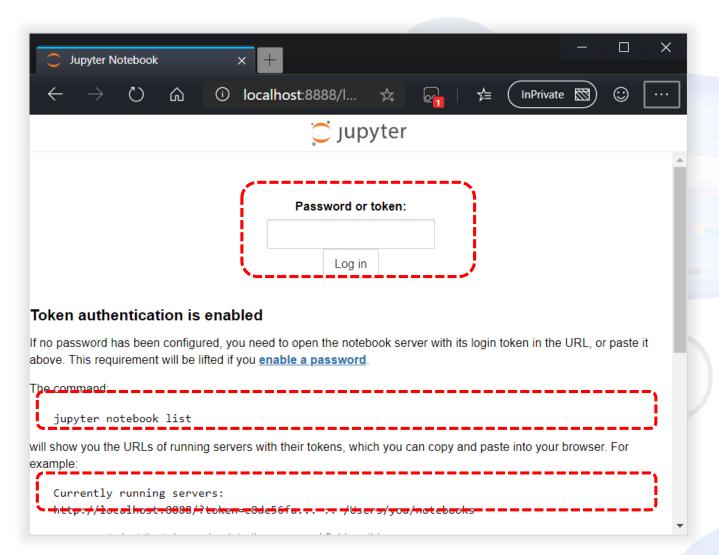
Jupyter Melalui SSH Tunneling ke EC2













Memanggil Spark di Jupyter

 Setelah instalasi modul findspark, ketikkan baris berikut di cell pertama Jupyter

```
import findspark
findspark.init()
import pyspark
sc = pyspark.SparkContext(appName="AppTerserah")
```

 Selanjutnya untuk akses Spark melalui SparkContext sc layaknya di PySpark Shell

```
import findspark
         findspark.init()
         import pyspark
         sc = pyspark.SparkContext(appName="myAppName")
In [4]: x = [1,2,3,4,5,6,7,8,9,10]
In [5]: rdd = sc.parallelize(x)
          ParallelCollectionRDD[0] at parallelize at PythonRDD.scala:195
         rdd.collect()
          [1, 2, 3, 4, 5, 6, 7, 8, 9, 10]
         rdd_map = rdd.filter(lambda x: x%2!=0)
         rdd_map.collect()
         hasil_reduce = rdd_map.reduce(lambda a,b: a+b)
         hasil_reduce
```